МИНОБРНАУКИ РОССИИ САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ «ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА) Кафедра МОЭВМ

ИНДИВИДУАЛЬНОЕ ДОМАШНЕЕ ЗАДАНИЕ по дисциплине «Разработка ПО информационных систем» Тема: Статистика студенческих отчётов

| Студенты гр. 6304 | Рыбин А.С. |
|-------------------|---------------------|
| | Ковынев М.В. |
| | Тимофеев А.А. |
| Преподаватель | Заславский М.М. |

Санкт-Петербург 2019

ЗАДАНИЕ

| Студенты: Рыбин А.С., Ковынев 1 | М.В., Тимофеев А.А |
|----------------------------------|--|
| Группа 6304. | |
| Тема проекта: Разработка прилож | ения «Статистика студенческих отчётов». |
| Исходные данные: Необходимо с, | делать приложение, которое позволяет: |
| стемматизировать текст отчетов, | исключать стоп слова, вычислять статистику |
| употребления отдельных слов, оп | ределять словарный запас, определять |
| пересечения словарных запасов. | |
| Предполагаемый объем поясните: | льной записки: |
| Не менее 15 страниц (обязательны | ы разделы «Содержание», «Введение», |
| «Выводы», «Список использовани | ных источников»). |
| Дата выдачи ИДЗ: | |
| Дата сдачи ИДЗ: | |
| Дата защиты ИДЗ: | |
| | |
| Студенты гр. 6304 | Рыбин А.С. |
| - | Ковынев М.В. |
| - | Тимофеев А.А. |
| Преполаватель | Заславский М.М. |

АННОТАЦИЯ

Исследование возможностей **нереляционных** баз данных на примере популярного **NoSQL** решения *MongoDB*. Проектирование и разработка приложения, ориентированного на хранение и анализ данных используя NoSQL БД (статистика студенческих отчётов). Сравнительный анализ **NoSQL** с традиционным **SQL** решением по сложности и количеству запросов и требуемому объёму памяти.

SUMMARY

Explore the capabilities of **non-relational** databases on the example of the popular *MongoDB* **NoSQL** solution. Design and development of an application focused on storing and analyzing data using NoSQL DB (statistics of student reports). Comparative analysis of **NoSQL** with traditional **SQL** solution for the complexity and number of queries and the required amount of memory.

СОДЕРЖАНИЕ

| 1. Введение | | | | 5 |
|-------------|-------|--------|------------------------------------|----|
| | 1.1. | Акт | уальность | 5 |
| | 1.2. | Пос | тановка задачи | 5 |
| | 1.3. | Пре | едлагаемое решение | 5 |
| 2. | Ка | честв | зенные требования к решению | 6 |
| | 2.1. | Тек | ущие | 6 |
| | 2.2. | Пер | оспективные | 6 |
| 3. | Cı | ценар | ии использования | 7 |
| | 3.1. | Mai | кет UI | 7 |
| | 3.2. | Сце | енарии использования для задачи | 8 |
| | 3.2 | 2.1. | Импорт/экспорт данных | 8 |
| | 3.2 | 2.2. | Загрузка нового отчета в систему | 8 |
| | 3.2 | 2.3. | Просмотр статистики | 9 |
| 4. | M | одель | данных | 0 |
| | 4.1. | NoS | SQL модель данных (MongoDB) | 0 |
| | 4.1 | 1.1. | Подробное описание и расчёт объёма | 0 |
| | 4.1 | 1.2. | Запросы | 2 |
| | 4.2. | SQI | L модель данных | 3 |
| | 4.2 | 2.1. | Подробное описание и расчёт объёма | 3 |
| | 4.2 | 2.2. | Запросы | 5 |
| | 4.3. | SQI | L vs NoSQL | 6 |
| 5. Pa | | зрабо | отанное приложение | 7 |
| | 5.1. | Экр | раны приложения | 7 |
| 5.2. | | Исп | пользованные технологии | .1 |
| | 5.3. | Ссь | лки: | .1 |
| Bı | ыводі | ы | 2 | 2 |
| Cı | писон | с испо | ользованных источников | 3 |
| П | ри по | JWEI | ние л | 1 |

1. Введение

1.1. Актуальность

Сама по себе идея нереляционных баз данных не нова, а использование нереляционных хранилищ началось ещё во времена первых компьютеров. Нереляционные базы данных процветали во времена мэйнфреймов, а позднее, во СУБД, доминирования реляционных нашли применение специализированных хранилищах, например, иерархических службах каталогов. Появление же нереляционных СУБД нового поколения произошло из-за необходимости создания параллельных распределённых систем ДЛЯ высокомасштабируемых интернет-приложений, таких как поисковые системы [1].

Поддержка гигантов индустрии менее чем за пять лет привела к широкому распространению технологий NoSQL (и подобных) для управления «большими данными», а к делу присоединились другие большие и маленькие компании, такие как: IBM, Facebook, Netflix, eBay, Hulu, Yahoo!, со своими проприетарными и открытыми решениями [1].

1.2. Постановка задачи

Необходимо сделать приложение, которое позволяет: стемматизировать текст отчетов, исключать стоп слова, вычислять статистику употребления отдельных слов, определять словарный запас, определять пересечения словарных запасов студентов.

1.3. Предлагаемое решение

В качестве решения выступает *веб* приложение, которое позволяет загружать отчёты, хранить отчёты в систематизированном виде и получать различную статистику, связанную с **текстом отчётов**, принадлежащих студенту, группе или факультету, или кафедре.

2. Качественные требования к решению

2.1. Текущие

- Для хранения данных используется **MongoDB**.
- Есть возможность массового импорта/экспорта из БД.
- Есть возможность получить статистику по загруженному отчёту.
- Есть возможность сравнить словарные запасы студентов.

2.2. Перспективные

- Авторизация студентов и преподавателей.
- Поддержка doc, pdf, odt.

3. СЦЕНАРИИ ИСПОЛЬЗОВАНИЯ

3.1. *Макет UI*

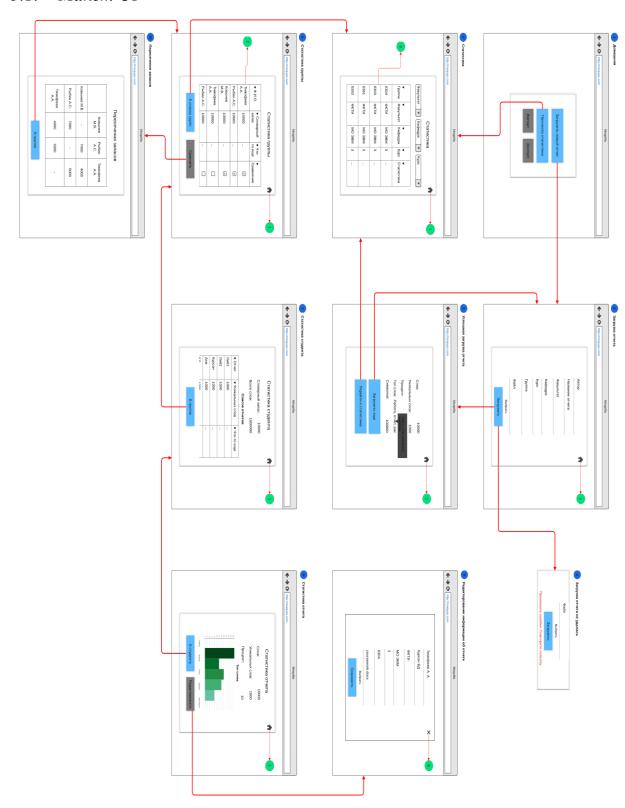


Рисунок 1 – Макет интерфейса пользователя

Макет также можно посмотреть по ссылке [7].

3.2. Сценарии использования для задачи

3.2.1. Импорт/экспорт данных

Действующее лицо: Пользователь

Импорт

Пользователь на главной странице нажимает кнопку "Импорт".

Пользователь загружает файл в формате **json.**

База данных отчетов обновляется в соответствии с загруженным файлом.

Экспорт

Пользователь на главной странице нажимает кнопку "Экспорт".

Пользователю предлагается загрузить файл в формате **json.**

3.2.2. Загрузка нового отчета в систему

Действующее лицо: Пользователь

Основной сценарий

Пользователь на главной странице нажимает кнопку "Загрузить новый отчет".

В форме ввода данных на следующей странице *пользователь* вводит мета информацию об загружаемом отчете и прикрепляет файл в формате **docx.**

Пользователь нажимает кнопку "Загрузить".

Пользователь видит сообщение об удачной загрузке отчета и подробную статистику по загруженному отчету.

Пользователь выполняет опциональные шаги.

Опциональные шаги

- Для загрузки еще одного отчета *пользователь* нажимает кнопку "Загрузить еще".
- Для перехода к просмотру статистики *пользователь* нажимает кнопку "Перейти к статистике".

Альтернативный сценарий (ошибка)

- Пользователь видит сообщение об ошибке загрузки.
- Пользователю предлагается повторить попытку загрузить отчет.

3.2.3. Просмотр статистики

Действующее лицо: Пользователь

Основной сценарий

На главной странице *пользователь* нажимает кнопку "Просмотр статистики".

Пользователь с помощью селекторов: "Кафедра", "Курс" и "Факультет" выбирает по каким группам отображать статистику.

Пользователю отображается страница с агрегированной статистикой по группам.

Пользователь выполняет опциональные шаги.

Опциональные шаги

- Для просмотра статистики по студентам группы *пользователь* нажимает на **строчку** с интересующей его группой.
- Для сравнения словарных запасов студентов *пользователь* на странице со статистикой группы выбирает нужных студентов с помощью чек-боксов и нажимает кнопку "Сравнить".
- Для просмотра подробной статистики и отчетов студента *пользователь* на странице со статистикой группы нажимает на **строчку** с интересующим его студентом.
- Для редактирования полей отчета и просмотра подробной статистики по отчету *пользователь* на странице со статистикой студента нажимает на **строчку** с интересующим его отчетом.

4. МОДЕЛЬ ДАННЫХ

4.1. NoSQL модель данных (MongoDB)

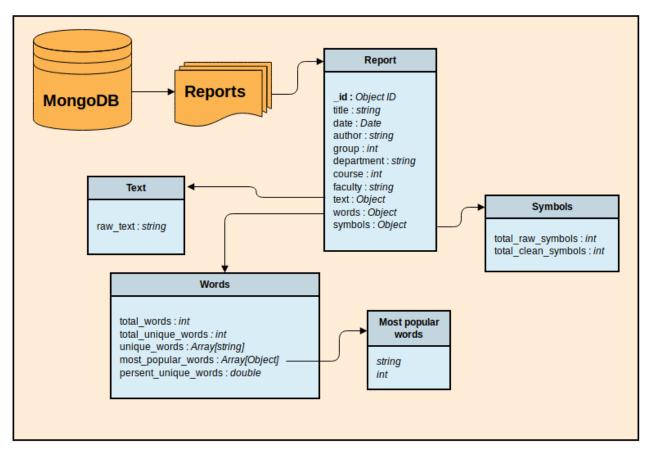


Рисунок 2 – NoSQL модель данных

4.1.1. Подробное описание и расчёт объёма

В качестве СУБД - **MongoDB**. В БД одна коллекция - *Reports*, в которой содержатся отчёты. Документы (отчёты) имеют следующие поля:

- _id идентификатор документа. Имеет тип *ObjectID*. V = 12b
- **title** название отчёта. Имеет тип *string*. V = 2b * Nt, где Nt средняя длина названия отчёта, пусть Nt = 20. Тогда V = 40b.
- date дата последней модификации отчёта. Имеет тип date. V = 8b
- **author** ФИО автора отчёта. Имеет тип *string*. V = 2b * Na, где Na средняя длина ФИО автора отчёта, пусть Na = 25. Тогда V = 50b.
- **group** номер группы автора отчёта. Имеет тип int. V = 4b

- **department** кафедра автора отчёта. Имеет тип *string*. V = 2b * Nd, где Nd средняя длина названия кафедры автора отчёта, пусть Nd = 10. Тогда V = 20b.
- **course** номер курса автора отчёта. Имеет тип int. V = 4b
- **faculty** факультет автора отчёта. Имеет тип *string*. V = 2b * Nf, где Nf средняя длина названия факультета автора отчёта, пусть Nd = 10. Тогда V = 20b.
- **text** вложенный документ, который содержит информацию о тексте отчёта. Имеет тип - *Object*
- **raw_text** текст отчёта. Имеет тип *string*. V = 2b * Nrt, где Nrt среднее количество символов в отчёте, пусть Nrt = 5000. Тогда V = 10000b.
- words вложенный документ, который содержит информацию о словах отчёта. Имеет тип *Object*
- total_words всего слов в отчёте. Имеет тип int. V = 4b
- total_unique_words всего уникальных слов в отчёте. Имеет тип int. V = 4b
- unique_words массив уникальных слов в отчёте. Имеет тип Array[string]. V = 2b * Nw * Nuw, где Nw средняя длина слова в отчёте, а Nuw среднее количество уникальных слов в отчёте, пусть Nw = 10; Nuw = 100. Тогда V = 2000b.
- **most_popular_words** массив пар слово-частота самых частых слов в отчёте. Имеет тип - Array[(string, int)]. V = (2b * Nw + 4b) * 20. V = 480b
- percent_unique_words процент уникальных слов в отчёте. Имеет тип double. V = 8b
- **symbols** вложенный документ, который содержит информацию о символах отчёта. Имеет тип *Object*
- total_raw_symbols количество символов в исходном тексте отчёта. Имеет тип int. $\mathbf{V} = \mathbf{4b}$
- total_clean_symbols количество символов в очищенном тексте отчёта. Имеет тип int. $\mathbf{V} = \mathbf{4b}$

Итого: объем документа в среднем 12662b = 12.4kB. Объем всей БД V = 12.4kb * N, где N количество отчётов в БД.

Например, если N = 1000, то объём БД 12.1mB

4.1.2. Запросы

Пример запроса на добавление отчёта

```
db['reports'].insert_one({
    'title': 'Курсовая',
    'date': '01.01.2012',
    'author': 'Иванов И.И.',
    'group': 1111,
    'department': 'MO∋BM'
    'course': 4
    'faculty': 'КТИ'
    'text': {
        'raw_text': 'отчёт и курсовая если .... NoSQL'
    'words': {
        'total_words': 10,
        'total_unique_words': 4,
        'unique words': [
            'отчёт', 'курсовая', 'БД', 'NoSQL'
        'most_popular_words': [
            ('отчёт': 3), ('курсовая': 5)
        'percent unique words': 40.0
    'symbols': {
        'total_raw_symbols': 100,
        'total_clean_symbols': 50
    }
})
```

Для добавления отчёта в БД нужен только один запрос. Например, чтобы добавить 1000 отчётов, запросов понадобится *1000*.

```
Пример запроса на получение всех отчётов автора db['reports'].find({'author': 'Иванов И.И.'}).sort('title')
```

Для получения всех отчетов автора нужен только один запрос. Также, чтобы ускорить выполнения данного запроса добавлен индекс по полю *author*:

```
db['reports'].create_index('author')
```

Пример запроса на получение статистики по группе

```
'avg_total_words': {'$avg': '$words.total_words'},
         'avg_unique_words': {'$avg': '$words.total_unique_words'},
         'avg_persent_unique_words': {'$avg': '$words.persent_unique_words'},
'unique_words': {'$addToSet': '$words.unique_words'},
         'avg_total_raw_symbols': {'$avg': '$symbols.total_raw_symbols'},
         'avg_total_clean_symbols': {'$avg': '$symbols.total_clean_symbols'},
         'total_reports_loaded': {'$sum': 1}
    },
{'$addFields': {
         'unique_words': {
              '$reduce': {
                  'input': '$unique_words',
                 'initialValue': [],
                  'in': {'$setUnion': ['$$value', '$$this']}
             }
        }
   }
    },
{'$addFields': {'total_unique_words': {'$size': '$unique_words'}}},
    {'$sort': {'_id': 1, 'total_unique_words': -1}}
])
```

Для получения статистики по группе нуден только один запрос. Также для ускорения в БД добавлены индексы по полям *author* и *group*:

```
self.db['reports'].create_index('group')
self.db['reports'].create_index('author')
```

4.2. SQL модель данных

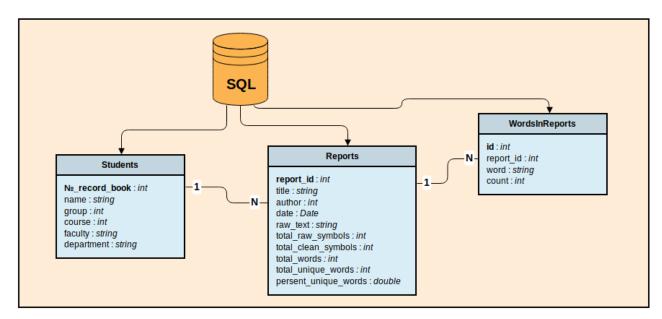


Рисунок 3 – Реляционная модель данных

4.2.1. Подробное описание и расчёт объёма

В БД будут три таблицы:

- *Students* таблица, содержащая информацию о студентах, которые загружали отчёты в БД. Включает поля:
 - \bigcirc **№_record_book №** зачётной книжки. Имеет тип *int*. **V** = **4b**
 - о **name** ФИО студента. Имеет тип *string*. V = 2b * Na, где Na средняя длина ФИО, Na = 25 из пред. пункта. Тогда V = 50b.
 - \circ group номер группы. Имеет тип *int*. $\mathbf{V} = \mathbf{4b}$
 - \circ course номер курса. Имеет тип *int*. $\mathbf{V} = \mathbf{4b}$
 - о **faculty** факультет. Имеет тип *string*. V = 2b * Nf, где Nf средняя длина названия факультета, Nd = 10 из пред. пункта. Тогда V = 20b.
 - о **department** кафедра. Имеет тип *string*. V = 2b * Nd, где Nd средняя длина названия кафедры, Nd = 10 из пред. пункта. Тогда V = 20b.

Итого: на одну запись в таблице 102b или 0.01kB

- *Reports* таблица, содержащая информацию об отчётах, загруженных в БД. Включает поля:
 - \circ report_id уникальный номер отчёта. Имеет тип *int*. $\mathbf{V} = \mathbf{4b}$
 - \circ **title** название отчёта. Имеет тип *string*. V = 2b * Nt, где Nt средняя длина названия отчёта, Nt = 20 из пред. пункта. Тогда V = 40b.
 - \circ **author** внешний ключ к таблице *Students*; указывает на автора отчёта. Имеет тип - *int*. **V** = **4b**
 - \circ date дата последней модификации отчёта. Имеет тип date. V = 8b
 - \circ raw_text текст отчёта. Имеет тип *string*. V = 2b * *Nrt*, где *Nrt* среднее количество символов в отчёте, *Nrt* = 5000 из пред. пункта. Тогда **V** = 10000b.
 - \circ **total_raw_symbols** количество символов в исходном тексте отчёта. Имеет тип - *int*. **V** = **4b**
 - \circ **total_clean_symbols** количество символов в очищенном тексте отчёта. Имеет тип - *int*. **V** = **4b**
 - \circ total_words всего слов в отчёте. Имеет тип *int*. $\mathbf{V} = \mathbf{4b}$
 - total_unique_words всего уникальных слов в отчёте. Имеет тип int. V =
 4b

percent_unique_words - процент уникальных слов в отчёте. Имеет тип double. V = 8b

Итого: на одну запись в таблице 10080b или 9.85kB

- WordsInReports таблица, содержащая информацию о уникальных словах и их количестве в отчёте. Включает поля:
 - \circ **id** уникальный № записи. Имеет тип *int*. **V** = **4b**
 - о **report_id** внешний ключ к таблице *Reports* информация, в каком отчёте встретилось слово. Имеет тип *int*. $\mathbf{V} = \mathbf{4b}$
 - \circ word слово. Имеет тип *string*. V = 2b * Nw, где Nw средняя длина слова в отчёте, Nw = 10 из пред. пункта. V = 20b
 - \circ **count** количество повторений в отчёте. Имеет тип *int*. **V** = **4b** Итого: на одну запись в таблице **32b** или **0.03kB**

Пусть:

- \circ *Nlr* среднее количество отчётов, которое загрузил каждый студент. *Nlr* = 5
- Nuw среднее количество уникальных слов в отчёте. Nuw = 100 из пред.
 пункта

Итого: для хранения N отчётов в бд понадобится:

$$V = 102b * N / Nlr + 10088b * N + 32b * Nuw * N = N * (20.4b + 10088b + 32b * 100) = N * 13308.4b = N * 13kB.$$

Например, если N = 1000 (как в пред. пункте), то объём БД 98.5mB

4.2.2. Запросы

Пример запроса на добавление студента

```
INSERT INTO Students (1111, 'Иванов И.И.', 6304, 3, 'КТИ', 'МОЭВМ')
Пример запросов, которые требуются для добавления отчёта
INSERT INTO Reports (111212, 'Курсовая', 1111, '01.01.2018', 'Курсовая работа исследование по База данных вывода задача технологии работа ЛЭТИ', 100, 50, 15, 5, 0.33)
INSERT INTO WordsInReports (3402340, 111212, 'работа', 2)
INSERT INTO WordsInReports (3402341, 111212, ..., ...)
INSERT INTO WordsInReports (3402342, 111212, ..., ...)
```

Пусть:

- \circ *Nlr* среднее количество отчётов, которое загрузил каждый студент. *Nlr* = 5
- Nuw среднее количество уникальных слов в отчёте. Nuw = 100 из пред.
 пункта

Итого, чтобы добавить N отчётов в БД потребуется:

$$N/Nlr + N + N * Nuw = N * (0.2 + 1 + 100) = N * 101.2$$
 запросов.

Например, если N = 1000 (как в пред. пункте), то запросов 101200

Пример запроса на получение всех отчётов автора

SELECT * FROM Reports
JOIN Students ON author=№_record_book
WHERE name='Иванов И.И.'

4.3. SQL vs NoSQL

SQL модель данных занимает больше места, т.к. SQL нет поддержки массивов и слова отчёта потребуется хранить как записи в отдельной таблице, что добавляет значительные накладные расходы за счёт дублирования информации.

По сравнению с SQL в NoSQL модели данных есть дублирование информации о студенте, загрузившем отчёт, но по сравнению, с местом которое требуется для хранения текста отчёта и слов, входящих в отчёт, это дублирование не вносит практически никакого вклада.

В SQL для загрузки N отчётов в БД потребуется N*101.2 запросов, а в NoSQL один запрос.

В итоге в SQL большее дублирование информации и расход места чем в NoSQL. К тому же *MongoDB* является документооринтированной СУБД и ее прямое назначение - работа со слабосвязанными и слабоструктурированными данными. Так что, выбор очевиден в пользу **MongoDB**.

5. РАЗРАБОТАННОЕ ПРИЛОЖЕНИЕ

Приложение позволяет загружать студенческие отчёты в формате docx и получать агрегированную статистику по ним для групп (с фильтром по факультету, кафедре и курсу), расширенную для отдельной группы, а также для отдельного студента. Предусмотрена возможность сравнивать словарные запасы (рассчитанные по всем отчётам студента) между одногруппниками.

5.1. Экраны приложения



Рисунок 4 – Главная страница

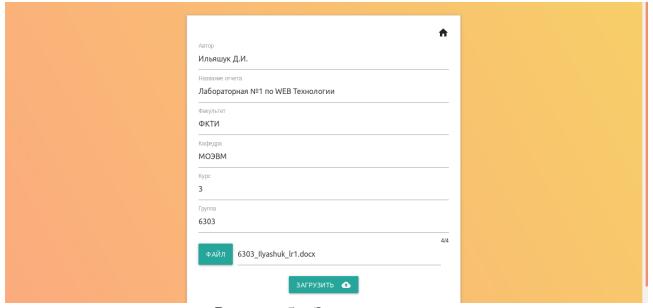


Рисунок 5 – Загрузка отчёта

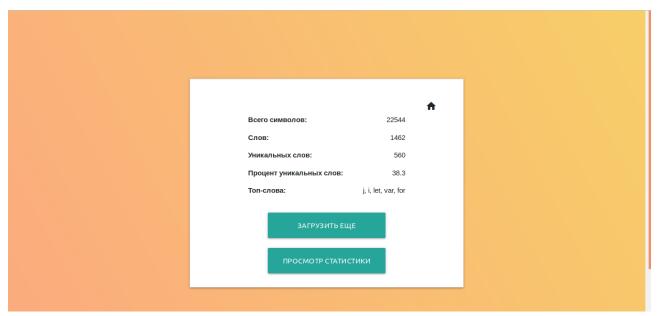


Рисунок 6 – Статистика после загрузки отчёта

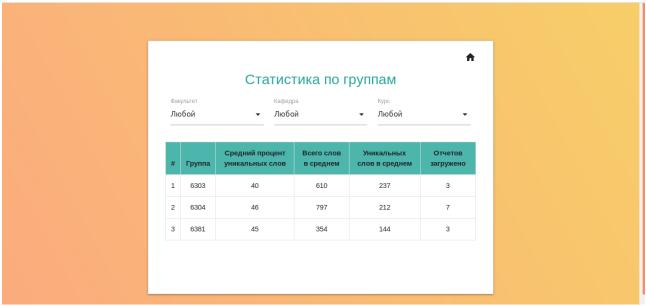


Рисунок 7 – Статистика по группам



Рисунок 8 – Статистика по группе



Рисунок 9 – Выбраны студенты для сравнения

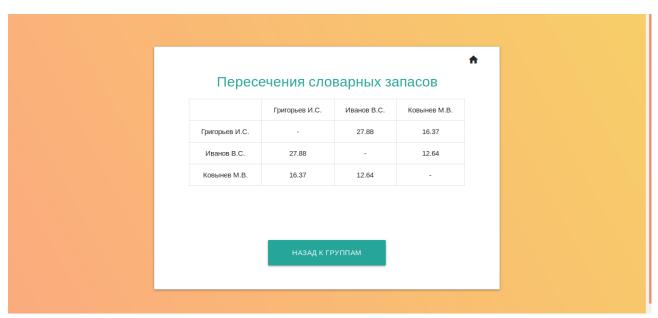


Рисунок 10 – Сравнение словарных запасов студентов



Рисунок 11 – Статистика по студенту

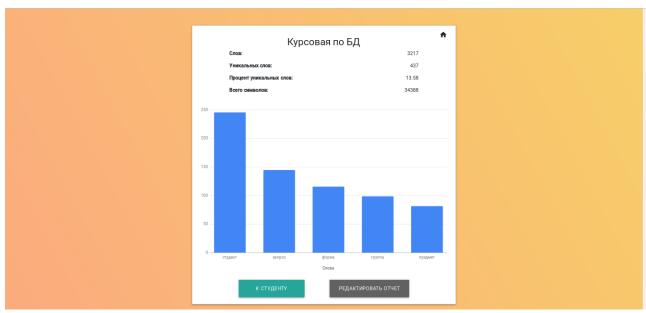


Рисунок 12 – Статистика по отчёту

5.2. Использованные технологии

Back-end представляет из себя *python* приложение с использованием фреймворка *Flask*, а для хранения данных задействована *MongoDB*. Приложение предоставляет *REST API* для загрузки отчётов и получения статистики по ним.

Front-end реализован с помощью встроенного во *Flask* шаблонизатора *Jinja2, JS* библиотеки *Jquery* и *CSS* фреймворков *Bootstrap, W3*.

5.3. Ссылки:

- Репозиторий проекта [8]
- Wiki проекта [9]

ВЫВОДЫ

В итоге выполнения ИДЗ реализовано приложение, позволяющее загружать, систематизировано хранить и обрабатывать студенческие отчёты. Однако приложение имеет следующие недостатки:

- Ограниченность формата отчёта (только **docx**)
- Хранение данных о студентах косвенно, в коллекции, предназначенной для хранения отчётов. Из этого следует: отсутствие авторизации, возможны дубликаты отчётов одного и того же студента, противоречивая информация об отчёте и т.д.

Скудный и малофункциональный Веб-интерфейс. Возможные пути улучшения:

- Добавить поддержку pdf, odt, plain text
- Реализовать более полную модель данных. Включить информацию о студентах в отдельную коллекцию, информацию о структуре кафедр и факультетов также включить в отдельную коллекцию.
- Модифицировать веб-интерфейс с использованием современных JS фреймворков (React, Angular, Vue)

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- 1. NoSQL // Википедия. URL: https://ru.wikipedia.org/wiki/NoSQL (дата обращения: 19.04.2019).
- 2. MongoDB Docs // WEB сайт MongoDB. URL: https://docs.mongodb.com/ (дата обращения: 19.04.2019).
- 3. Welcome to Flask // WEB сайт Flask. URL: http://flask.pocoo.org/docs/1.0/ (дата обращения: 19.04.2019).
- 4. jQuery API // WEB сайт Jquery. URL: https://api.jquery.com/ (дата обращения: 19.04.2019).
- 5. Bootstrap // WEB сайт Bootstrap. URL: https://getbootstrap.com/ (дата обращения: 19.04.2019).
- 6. Python 3.7.3 documentation // WEB сайт Python. URL: https://docs.python.org/3/ (дата обращения: 19.04.2019).
- 7. Макет UI // GitHub WIKI проекта. URL: https://github.com/moevm/nosql1h19-report-stats/wiki/%D0%9C%D0%B0%D0%BA%D0%B5%D1%82-UI (дата обращения: 19.04.2019).
- 8. Репозиторий проекта // GitHub. URL: https://github.com/moevm/nosql1h19-report-stats (дата обращения: 19.04.2019).
- 9. WIKI проекта // GitHub WIKI проекта. URL: https://github.com/moevm/nosql1h19-report-stats/wiki (дата обращения: 19.04.2019).

ПРИЛОЖЕНИЕ А

ИНСТРУКЦИЯ ПО СБОРКЕ И ЗАПУСКУ

- 1. Клонировать Репозиторий проекта
- 2. Перейти в папку с репозиторием
- 3. Собрать docker образ командой
- o docker-compose build
- 4. Создать volume, в котором персистентно будут храниться данные БД с помощью команды
- o docker volume create nosql1h19-report-stats-data
- 5. Запустить контейнер командой
- docker-compose up -d
- 6. Перейти на localhost:5000
- 7. Для остановки контейнера выполнить команду
- docker-compose stop